

Detecção de Anomalias

Prof. Danilo Silva


EEL7514/EEL7513 - Tópico Avançado em Processamento de Sinais

EEL410250 - Aprendizado de Máquina

EEL / CTC / UFSC

Introdução

Detecção de Anomalias (ou Outliers)




- ▶ Objetivo: detectar casos que fogem ao “normal” (comum / esperado)
- ▶ Aplicações:
 - ▶ Detecção de intrusos / atividade maliciosa / fraudes
 - ▶ Detecção de falhas em sistemas
 - ▶ Monitoramento de saúde

Detecção de Anomalias (ou Outliers)

- ▶ Tipos de aprendizado:
 - ▶ **Supervisionado:** Requer amostras rotuladas como normais e anômalas
 - ▶ Equivalente a classificação binária com alto desbalanceamento
 - ▶ **Semi-Supervisionado:** Requer apenas amostras normais
 - ▶ Também conhecido como **detecção de novidade**
 - ▶ **Não-Supervisionado:** Requer apenas amostras não-rotuladas
 - ▶ Assume-se que a proporção de anomalias é pequena
- ▶ Abordagens:
 - ▶ Baseada em classificação (ex: SVM de única classe)
 - ▶ Vizinhança/clustering
 - ▶ Redução de dimensionalidade (ex: PCA, redes neurais *autoencoders*)
 - ▶ Modelamento estatístico (estimação de densidade de probabilidade)

One-Class SVM



Estimação de Densidade

- ▶ **Princípio básico:** uma amostra é classificada como anômala se possui baixa probabilidade de ocorrência (abaixo de um limiar pré-estabelecido)

$$p(\mathbf{x}) < \epsilon$$

Tipos:

- ▶ **Estimação paramétrica:** assume um modelo específico caracterizado por uma densidade de probabilidade com parâmetros livres a serem ajustados pelos dados (ex: modelo gaussiano)
- ▶ **Estimação não-paramétrica:** não faz hipóteses sobre o modelo, ao invés disso determina a densidade a partir dos dados (ex: histograma)

Modelos Gaussianos

Modelo Gaussiano (Univariável)

- ▶ $n = 1 \implies \mathbf{x} = (x_1) = x \in \mathbb{R}$
- ▶ Densidade de probabilidade ($x \sim \mathcal{N}(\mu, \sigma^2)$):

$$p(x; \mu, \sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$$


- ▶ Estimação de máxima verossimilhança:

$$\mu = \frac{1}{m} \sum_{i=1}^m x^{(i)}$$

$$\sigma^2 = \frac{1}{m} \sum_{i=1}^m (x^{(i)} - \mu)^2$$

- ▶ Estimação não-enviesada de σ^2 : divida por $m - 1$ ao invés de m
 - ▶ Obs: irrelevante para m suficientemente grande

Exemplo



Modelo Gaussiano Multivariável

- Densidade de probabilidade ($\mathbf{x} \in \mathbb{R}^n$, $\mathbf{x} \sim \mathcal{N}(\boldsymbol{\mu}, \boldsymbol{\Sigma})$):


$$p(\mathbf{x}; \boldsymbol{\mu}, \boldsymbol{\Sigma}) = \frac{1}{\sqrt{(2\pi)^n \det(\boldsymbol{\Sigma})}} e^{-\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu})^T \boldsymbol{\Sigma}^{-1}(\mathbf{x} - \boldsymbol{\mu})}$$

- Estimação de máxima verossimilhança:


$$\boldsymbol{\mu} = \frac{1}{m} \sum_{i=1}^m \mathbf{x}^{(i)}$$
$$\boldsymbol{\Sigma} = \frac{1}{m} \sum_{i=1}^m (\mathbf{x}^{(i)} - \boldsymbol{\mu})(\mathbf{x}^{(i)} - \boldsymbol{\mu})^T$$

- Obs: requer $m > n$ para que $\boldsymbol{\Sigma}$ seja inversível
- Modelar cada x_j como uma variável gaussiana independente equivalente a modelar $\mathbf{x} \sim \mathcal{N}(\boldsymbol{\mu}, \boldsymbol{\Sigma})$ onde $\boldsymbol{\Sigma} = \text{diag}(\sigma_1^2, \dots, \sigma_n^2)$
 - Nesse caso, se houver correlação nos dados ela não será identificada
 - Em compensação, requer menor complexidade e menos dados


Exemplo



Exemplo




Exemplo



Recomendações

- ▶ Visualize os dados antes de modelar
- ▶ Mesmo que a distribuição não seja aproximadamente gaussiana, é possível que se torne aproximadamente gaussiana após alguma transformação
 - ▶ Ex: X é log-normal $\implies Y = \log(X)$ é gaussiana
- ▶ Escolha atributos que possam variar significativamente no caso de uma anomalia
- ▶ Se possível, ajuste o modelo em amostras normais; se possuir amostras anômalas, guarde-as para validação e/ou teste
- ▶ Caso possua apenas amostras não-rotuladas para treinamento (possivelmente “contaminadas” com anomalias), torna-se importante usar um método de estimação de covariância **robusto**

Exemplo



Avaliação do Modelo

- ▶ Amostras rotuladas como anômalas podem ser usadas para avaliação do modelo
- ▶ Deve ser usada uma métrica robusta a desbalanceamento das classes (não usar acurácia):
 - ▶ Curva ROC (TPR x FPR)
 - ▶ Curva Precision-Recall

$$P = \frac{T_p}{T_p + F_p}, \quad R = \frac{T_p}{T_p + F_n}$$

- ▶ F_1 score (obs: “Positivo” = “Anômalo”):

$$F_1 = 2 \frac{PR}{P + R} = \frac{2T_p}{2T_p + F_n + F_p}$$

- ▶ Vantagem de ser um único número

Como Determinar o Limiar?

- ▶ Amostras rotuladas como anômalas também podem ser usadas para escolher o limiar ϵ , através de um conjunto de validação
- ▶ Escolha ϵ que maximiza o desempenho no conjunto de validação